

Structurer les données est indispensable pour les manipuler dans les programmes.

Il faut cependant savoir retrouver les données dans ces structures, c'est le but des algorithmes de **recherche**, et de **tri**.

The Analytical Engine has no pretensions whatever to originate anything. It can do whatever we know how to order it to perform.

Ada Lovelace (1815-1852) - Notes on the Sketch of The Analytical Engine.



Le **problème** est de trouver un élément dans une structure linéaire (tableau).

- l'élément peut ne pas être présent
- l'élément peut être présent à plusieurs endroits
- si la structure a plusieurs dimensions, il faut fouiller chaque dimension

Technique intuitive : la **recherche séquentielle**

- on parcourt la structure dans l'ordre « naturel »
- on s'arrête au bout, ou quand on trouve l'élément
- parfois on peut s'arrêter plus tôt

Recherche séquentielle : on s'arrête quand on trouve l'élément, ou quand on arrive au bout du tableau

```
// cette fonction renvoie vrai si x est présente dans tab, faux sinon
fonction avec retour booléen rechercheElement1(chaine tab[], chaine
e)
    entier i;
    booléen trouve;
début
    i <- 0;
    trouve <- faux;
    tantque (i < tab.longueur et non trouve) faire
        si (tab[i] = e) alors
            trouve <- vrai;
        sinon
            i <- i + 1;
        finsi
    fintantque
    retourne trouve;
fin
```

Variante : on cherche le nombre d'occurrences d'un élément

```
// cette fonction renvoie le nombre de fois où x est présente dans
tab
fonction avec retour entier rechercheElement3(chaine tab[], chaine e)
    entier i, nbOc;
début
    i <- 0;
    nbOc <- 0;
    tantque (i < tab.longueur) faire
        si (tab[i] = e) alors
            nbOc <- nbOc + 1;
        finsi
        i <- i + 1;
    fintantque
    retourne nbOc;
fin
```

Optimisation : si le tableau est trié, on peut s'arrêter plus « tôt »


```
// cette fonction renvoie vrai si x est présente dans tab, faux sinon
// le tableau tab est supposé trié par ordre croissant
fonction avec retour booléen rechercheElement4(chaine tab[], chaine
e)
    entier i;
    booléen trouve,possible;
début
    i <- 0;
    trouve <- faux;
    possible <- vrai;
    tantque (i < tab.longueur et possible et non trouve) faire
        si (tab[i] = e) alors
            trouve <- vrai;
        sinon
            si (tab[i] > x) alors
                possible <- faux;
            sinon
                i <- i + 1;
            finsi
        finsi
    fintantque
    retourne trouve;
fin
```

Remarque : il n'y a optimisation que si on trouve « assez vite » un point

d'arrêt

Principe diviser pour régner : on découpe les données en différentes parties qu'on traite séparément.

Exemple : pour rechercher un élément dans un tableau, on le coupe en deux et on cherche dans chaque partie.



Ce principe est utile :

- si on peut lancer des programmes en parallèle, on mettra environ deux fois moins de temps pour rechercher l'élément.
- si le tableau est trié, on peut ne chercher l'élément que dans une seule des parties.

Recherche par dichotomie : le tableau est supposé trié par ordre croissant et on cherche un élément e dans un tableau t

Principe de l'algorithme :

- 0- on regarde l'élément situé au milieu de t :
- 1- s'il s'agit de e c'est gagné.
- 2- s'il est plus grand que e , on cherche dans la moitié gauche
- 3- s'il est plus petit que e , on cherche dans la moitié droite

Remarques :

- ça ne peut marcher que si le tableau est trié
- on coupe le tableau en deux parties pas forcément égales en taille

Exemple : rechercher 490 dans le tableau d'entiers suivant.

4	17	25	26	45	45	87	102	234	237	490	121 3	568 1	569 0	701 2
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
4	17	25	26	45	45	87	102	234	237	490	121 3	568 1	569 0	701 2
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
4	17	25	26	45	45	87	102	234	237	490	121 3	568 1	569 0	701 2
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
4	17	25	26	45	45	87	102	234	237	490	121 3	568 1	569 0	701 2
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14

Remarque : on trouve 490 en 4 itérations, une recherche séquentielle aurait demandé 11 itérations


```
// cette fonction renvoie vrai si x est présente dans tab, faux sinon
// le tableau tab est supposé trié par ordre croissant
fonction avec retour booléen rechercheElement3(chaine tab[], chaine e)
    entier i, j;
    booléen trouve;
début
    trouve <- false;
    i <- 0;
    j <- tab.longueur-1;
    tantque (i <= j et non trouve) faire
        si (tab[(j+i)/2] = e) alors
            trouve <- vrai;
        sinon
            si (tab[(j+i)/2] > e) alors
                j <- (j+i)/2 - 1;
            sinon
                i <- (j+i)/2 + 1;
            finsi
        finsi
    fintantque
    retourne trouve;
fin
```

Recherche par interpolation : on améliore la recherche par dichotomie en coupant le tableau non pas au milieu, mais à un endroit « proche » de la valeur cherchée.

La recherche par interpolation suppose qu'on puisse interpoler l'indice probable de la valeur recherchée.


Exemple : chercher un mot dans le dictionnaire se fait par interpolation

Interpoler l'indice où on peut trouver un élément dans un tableau implique qu'on connaisse à l'avance la répartition des éléments (au moins approximativement).


Un cas simple : les éléments sont répartis **linéairement** dans le tableau.

4	17	25	26	45	45	87	102	234	237	490	121 3	568 1	569 0	701 2
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14

4	17	25	26	45	45	63	71	77	89	98	101	104	112	124
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14



indice interpolé de 490 = 1




indice interpolé de 71 = 8

Si on suppose une **répartition ordonnée et linéaire** des valeurs dans un tableau `tab`, on peut interpoler linéairement la place d'un élément `e` recherché entre des indices `i` et `j`.

$$a = (\text{tab}[j] - \text{tab}[i]) / (j - i)$$

$$b = \text{tab}[i] - a*i$$

$$k = (e - b) / a$$



L'algorithme de recherche par interpolation est le même que celui de recherche dichotomique, mais à chaque itération, au lieu de tester l'élément situé à l'indice $(i+j)/2$, on teste celui situé en k .

La recherche d'élément paraît plus efficace dans les tableaux triés. Il est donc intéressant de pouvoir tester si un tableau est trié et, si ce n'est pas le cas, de pouvoir le trier.

Tester si un tableau est **trié par ordre croissant** : on s'assure que chaque case (sauf la dernière) a un contenu plus petit que celui de la case suivante.

```
fonction avec retour booléen testTrie1(entier tab[])
  entier i;
  booléen b;
début
  b <- VRAI;
  pour (i allant de 0 à tab.longueur-2 pas 1) faire
    si (tab[i] > tab[i+1]) alors
      b <- FAUX;
    finsi
  finpour
  retourne b;
fin
```

Optimisation : on peut s'arrêter dès qu'on trouve deux éléments qui ne sont pas dans le bon ordre.

```
fonction avec retour booléen testTrie2(entier tab[])
  entier i;
  booléen b;
début
  b <- VRAI;
  i <- 0;
  tantque (i < tab.longueur-1 et b) faire
    si (tab[i] > tab[i+1]) alors
      b <- FAUX;
    finsi
    i <- i+1;
  finpour
  retourne b;
fin
```

Le **problème** est de placer les éléments d'une structure linéaire dans l'ordre

- les éléments doivent pouvoir être comparés
- on peut trier par ordre croissant ou décroissant
- si la structure a plusieurs dimensions, on peut trier chaque dimension


De nombreux algorithmes de tri existent, qui ont chacun leurs avantages et inconvénients en fonction des données à trier.

Certains algorithmes utilisent des structures de données plus complexes (arbres en particulier).


On ne voit ici que quelques tris de base.

Occupation mémoire d'un algorithme de tri :

- **tri en place** : les éléments sont triés dans la structure de données




- **tri pas en place** : on crée une nouvelle structure de données




Stabilité d'un algorithme de tri :

- **tri stable** : l'algorithme ne modifie pas l'ordre initial des éléments égaux



- **tri instable** : l'algorithme modifie l'ordre initial des éléments égaux



Tri à bulle (bubble sort) : on remonte le plus grand élément par permutations et on recommence jusqu'à ce que le tableau soit trié.

Exemple : trier par ordre croissant le tableau suivant

17	2	268	415	45	45	102	701
----	---	-----	-----	----	----	-----	-----

2	17	268	45	45	102	415	701
---	----	-----	----	----	-----	-----	-----

2	17	45	45	102	268	415	701
---	----	----	----	-----	-----	-----	-----

2	17	45	45	102	268	415	701
---	----	----	----	-----	-----	-----	-----

...

Remarques :

- le tri à bulle est en place. Il est stable si on permute uniquement les éléments différents.
- on pourrait faire remonter le plus petit élément.
- on pourrait s'arrêter dès que le tableau est trié

Algorithme de tri à bulle d'un tableau d'entier, par ordre croissant :

```
fonction sans retour triBulle(entier tab[])
  entier i,j,temp;
début
  pour (i allant de tab.longueur-2 à 1 pas -1) faire
    pour (j allant de 0 à i pas 1) faire
      si (tab[j] > tab[j+1]) alors
        temp <- tab[j];
        tab[j] <- tab[j+1];
        tab[j+1] <- temp;
      finsi
    finpour
  finpour
fin
```

Remarque : ce tri est stable, il serait non stable si on avait mis `tab[j] >= tab[j+1]`

Optimisation : on s'arrête dès que le tableau est trié.


```
fonction sans retour triBulle(entier tab[])
  entier i,j,temp;
  booléen trié;
début
  trié <- faux;
  i <- tab.longueur-2;
  tantque ((non trié) et (i > 0)) faire
    trié <- vrai;
    pour (j allant de 0 à i pas 1) faire
      si (tab[j] > tab[j+1]) alors
        temp <- tab[j];
        tab[j] <- tab[j+1];
        tab[j+1] <- temp;
        trié <- faux;
      finsi
    finpour
    i <- i-1;
  fintantque
fin
```

Remarque : cette amélioration n'est efficace que si le tableau est déjà « un peu » trié et qu'il devient trié « assez vite ».

Amélioration : à chaque itération, on remonte le plus grand élément à un bout et le plus petit élément à l'autre bout.

```
fonction sans retour triBulleBoustrophédon(entier tab[])
  entier i,j,k,temp;
  booléen trié;
début
  trié <- faux; j <- tab.longueur; i <- -1;
  tantque ((non trié) et (j > i)) faire
    trié <- vrai;
    pour (k allant de i+1 à j-2 pas 1) faire
      si (tab[k] > tab[k+1]) alors
        temp <- tab[k]; tab[k] <- tab[k+1]; tab[k+1] <- temp;
        trié <- faux;
      finsi
    finpour
    j <- j-1;
    pour (k allant de j-1 à i+2 pas -1) faire
      si (tab[k] < tab[k-1]) alors
        temp <- tab[k]; tab[k] <- tab[k-1]; tab[k-1] <- temp;
        trié <- faux;
      finsi
    finpour
    i <- i+1;
  fintantque
fin
```

Test expérimental sur des tableaux d'entiers générés aléatoirement



Tri par sélection (selection sort) : on parcourt le tableau pour trouver le plus grand élément, et une fois arrivé au bout du tableau on y place cet élément par permutation. Puis on recommence sur le reste du tableau.

```
fonction sans retour triSelection(entier tab[])
  entier i,j,temp,pq;
debut
  i <- tab.longueur-1;
  tantque (i > 0) faire
    pq <- 0;
    pour (j allant de 0 à i pas 1) faire
      si (tab[j] > tab[pq]) alors
        pq <- j;
      finsi
    finpour
    temp <- tab[pq];
    tab[pq] <- tab[i];
    tab[i] <- temp;
    i <- i-1;
  fintantque
fin
```

Le tri sélection n'effectue qu'une permutation pour remonter le plus grand élément au bout du tableau, il est donc plus efficace que le tri à bulle.

Le tri sélection est en place et l'algorithme donné ici est stable. Il serait instable si on remplaçait la comparaison `tab[j] > tab[pg]` par `tab[j] >= tab[pg]`.

Le tri sélection peut être amélioré en positionnant à chaque parcours du tableau le plus grand et le plus petit élément, selon le même principe que celui utilisé pour le tri à bulle boustrophédon.

Tri par insertion (insertion sort) : on prend deux éléments qu'on trie dans le bon ordre, puis un 3e qu'on insère à sa place parmi les 2 autres, puis un 4e qu'on insère à sa place parmi les 3 autres, etc.

2	17	45	45	102	268	415	701
---	----	----	----	-----	-----	-----	-----

```
fonction sans retour triInsertion(entier tab[])
  entier i, j, val;
debut
  pour (i allant de 1 à tab.longueur-1 pas 1) faire
    val <- tab[i];
    j <- i;
    tantque ((j > 0) et (tab[j-1] > val)) faire
      tab[j] <- tab[j-1];
      j <- j-1;
    fintantque
      tab[j] <- val;
  finpour
fin
```

L'algorithme de tri par insertion donné ici est en place et stable (il serait instable si on utilisait \geq au lieu de $>$).


Le **tri par sélection** nécessite en moyenne de l'ordre de $n^2/2$ comparaisons, n étant la taille du tableau : on fera d'abord $n-1$ tours de la boucle pour, puis $n-2$, et ainsi de suite jusqu'à 1.

Le **tri par insertion** nécessite en moyenne de l'ordre de $n^2/4$ comparaisons et déplacements : placer le $i^{\text{ème}}$ élément demande en moyenne $i/2$ comparaisons.


Le tri par insertion est donc environ deux fois plus rapide que le tri par sélection.

Efficacité des tris à bulle, par sélection et par insertion

Test expérimental sur des tableaux d'entiers générés aléatoirement.



Tri fusion (merge sort, John von Neumann, 1945) : on coupe le tableau en deux et on trie chacune des sous-parties (diviser pour régner), puis on reconstitue le tableau entier en fusionnant les deux parties et en respectant l'ordre.



Pour écrire l'algorithme on va appliquer le principe à l'envers : on fusionne des blocs de une case, puis des blocs de deux cases, etc.

4	7	12	15	32	45	67	102
---	---	----	----	----	----	----	-----

Fusionner les deux sous-parties d'un tableau « en place », oblige à réaliser de nombreux décalages. Pour gagner du temps, on va consommer de l'espace mémoire en utilisant un tableau temporaire.

```
// fusion des parties de tab d'indices dans [a,b] et [b+1,c] avec a<b<=c
// les elements de ces parties sont tries en ordre croissant
fonction sans retour fusion(entier tab[],entier a, entier b, entier c)
    entier i, j, k, t[c-a+1];
début
    pour (i allant de 0 à t.longueur-1 pas de 1) faire
        t[i] <- tab[a+i];
    finpour
    i <- 0, j <- b-a+1, k <- a;
    tantque(k <= c){
        si (i <= b-a et (j = c-a+1 ou t[i] <= t[j])) alors
            tab[k] <- t[i];
            i++;
        sinon
            tab[k] <- t[j];
            j++;
        finsi
        k++;
    fintantque
fin
```

Attention, il faut gérer le cas où le dernier bloc dépasse du tableau.

```
fonction sans retour triFusion(entier tab[])
    entier i, n;
debut
    n <- 1;
    tantque (n <= tab.longueur) faire
        pour (i allant de 0 à tab.longueur-1 pas 2n) faire
            si (i+2n-1 < tab.longueur) alors
                fusion(tab,i,i+n-1,i+2n-1);
            sinon
                si (i+n <= tab.longueur-1) alors
                    fusion(tab,i,i+n-1,tab.longueur-1);
                finsi
            finsi
        finpour
        n <- 2n;
    fintantque
fin
```

Remarque : l'algorithme de tri fusion donné ici n'est pas en place mais stable (il serait instable si on utilisait $<$ au lieu de \leq dans l'algorithme de fusion).


Tri rapide (quick sort, Charles Hoare, 1960) : on trie un élément (dit pivot) en déplaçant à sa gauche les éléments plus petits et à sa droite les éléments plus grands. Puis on recommence l'opération sur les deux sous parties gauche et droite.



4	7	12	15	55	67	69	102
---	---	----	----	----	----	----	-----

Pour partitionner une section $[a,b]$ d'un tableau t , on peut le parcourir séquentiellement :

- au départ le pivot est dans la case $p=a$
- à tout moment, le pivot est dans la case p et tous les éléments entre a et $p-1$ sont plus petits que le pivot




On partitionne en prenant pour pivot le premier élément de l'intervalle d'indices et en perdant complètement l'ordre initial. On pourrait imaginer un algorithme de partition stable, mais il serait moins efficace.

```
// partitionne la section [a,b] de tab utilisant tab[a] comme pivot
// renvoie l'indice du pivot après partition
fonction avec retour entier partition(entier tab[], entier a, entier b)
    entier pivot, i, temp;
debut
    pivot <- a;
    pour (i allant de a+1 à b pas de 1) faire
        si (tab[i]<tab[pivot]) alors
            temp <- tab[i];
            tab[i] <- tab[pivot+1];
            tab[pivot+1] <- tab[pivot];
            tab[pivot] <- temp;
            pivot <- pivot+1;
        finsi
    finpour
    retourne pivot;
fin
```


On doit mémoriser au fur et à mesure les sections de tableau à partitionner.

```
fonction sans retour triRapide(entier tab[])
  entier pile[tab.longueur];
  entier top = 1, a, b, p;
debut
  pile[0] <- 0;
  pile[1] <- tab.longueur-1;
  tantque (top>=0) faire
    a <- pile[top-1];
    b <- pile[top];
    top <- top-2;
    p <- partition(tab,a,b);
    si (p-1>a) alors
      pile[top+1] <- a;
      pile[top+2] <- p-1;
      top <- top+2;
    finsi
    si (p+1<b) alors
      pile[top+1] <- p+1;
      pile[top+2] <- b;
      top <- top+2;
    finsi
  fintantque
fin
```

Test expérimental sur des tableaux d'entiers générés aléatoirement.



Test expérimental sur des tableaux d'entiers générés aléatoirement.

